

TableNet: 一个基于大型语言模型（LLM）实现自主生成功能的大规模表格数据集

张瑞林、杨凯*

同济大学计算机科学与技术学院
中国上海市曹安路4800号，邮编：201804

摘要

表格结构识别（TSR）需要大型语言模型（LLM）具备处理复杂表格布局的逻辑推理能力，但现有数据集在规模和质量上均存在局限，阻碍了这种推理能力的有效应用。为此，我们推出了**TableNet数据集**——一个通过多源数据采集与生成的新建表格结构识别数据集。本研究的核心在于我们开发的首个**基于LLM的自主表格生成与识别多智能体系统**。该系统的生成模块将可控的视觉特征、结构参数及语义参数整合到表格图像合成过程中，能够创建多种语义连贯的表格，并可根据用户定义的配置及标注需求进行灵活调整，从而支持大规模、高精度的数据集构建。这一功能实现了全面且细致的表格图像标注分类体系，有望推动相关领域的研究发展。与传统数据收集方法相比，该方法能够实现理论上无限、领域无关且风格灵活的表格图像生成，同时确保高效性和准确性。我们系统的识别模块采用基于多样性的主动学习范式：利用来自多个来源的表格数据，并选择性采样最具信息量的数据来微调模型，在TableNet测试集上取得优异性能的同时，相较于基线模型大幅减少了训练样本数量；在基于网络爬取的真实世界表格数据集上的表现也远超基于主流表格数据集训练的模型。据我们所知，这是首个将主动学习概念应用于表格结构识别的研究——这类表格在行数/列数、合并单元格及单元格内容等方面具有高度多样性，非常适合基于多样性的主动学习方法。

数据集——<https://huggingface.co/datasets/匿名用户123123/TableNet/tree/main>

引言

表格结构识别（TSR）旨在从图像中恢复表格的逻辑结构。尽管近年来已取得进展，但由于表格布局、样式及语义存在显著差异，该任务仍具有挑战性。

*通讯作者。

版权所有 © 2026，人工智能促进协会（www.aaai.org）。保留所有权利。

这些数据集通常包含复杂的视觉特征——如合并的单元格、缺失的边框、不一致的对齐方式或异质化的色彩方案，这给大型语言模型（LLM）解析表格结构时的逻辑推理能力带来挑战。然而，现有数据集在规模、多样性和标注质量方面往往存在局限，难以充分发挥LLM的逻辑推理能力。

为解决这些局限性，我们推出了TableNet数据集以及首个基于大语言模型（LLM）的自主表格生成与识别多智能体系统。通过整合可控参数，该系统能够以极低的人工干预成本生成多种类型的表格。与传统数据集收集方法不同，我们的系统充分利用了大语言模型中预置的先验知识，并支持用户自定义配置，从而能够生成可扩展、可控且语义连贯的表格及其对应标注。

TableNet广泛的风格覆盖范围和领域适用性促使人们采用主动学习方法——该方法能为模型训练选择最具信息量的样本，并可应用于入侵检测/异常检测（Zhu and Yang 2019; Yang et al. 2018）、计算机视觉（Beluch et al. 2018）等诸多领域的数据过滤任务。这一过程可通过算法1（Xia et al. 2025）所示的五步流程来描述：初始化、查询、标注、训练和停止。现有的主动学习方法主要可分为两大类：基于多样性的方法和基于不确定性的方法。基于多样性的方法（Gissin and Shalev-Shwartz 2019; Sener and Savarese 2017）旨在选取能够代表整体分布特征的子集；而基于不确定性的方法（Beluch et al. 2018; Gal, Islam, and Ghahramani 2017; Yoo and Kweon 2019）则优先处理模型无法准确预测的样本。基于多样性的主动学习方法特别适用于异构表格结构场景。通过主动从多个来源中选取训练样本，我们的TSR模型在TableNet测试集上实现了具有竞争力的性能表现；同时所需样本量显著减少，并且在从未见过的真实世界表格进行评估时，其性能明显优于基于现有数据集训练的模型。

本文的主要贡献可总结如下。

- 我们发布了TableNet——一个大规模表格数据集，其内容包括由可控的基于大语言模型的多智能体系统生成的合成表格、从网络采集的真实世界表格以

及增强型开源数据集，从而确保了视觉风格、结构和语义层面的多样性。

- 我们开发了首个基于大语言模型（LLM）的自主多智能体系统，能够生成具有用户可配置属性的表格图像，从而实现大规模真实数据集的合成，并为TSR技术提供基础支持。
- 我们采用基于多样性的主动学习策略来训练系统的表格结构识别模块。通过使用主动选取的样本进行训练，我们的模型在测试集上仅需极少训练样本即可取得优异性能，并且其表现优于在其他公开数据集上针对网络爬取的未见过真实世界表格训练得到的模型。

相关作品

表结构识别（TSR）。表是由行和列系统排列的数据组织形式，其网格格式能显著提升清晰度与处理效率。TSR旨在分析表格图像的布局，并通过标记语言（Zhong、Shafiei-Bavani 和 Jimeno-Yepes 2020; Nassar 等人 2022）、电子表格（Koci 等人 2017）及图表（Koci 等人 2019、2018; Qasim、Mahmood 和 Shafait 2019; Xue、Li 和 Tao 2019; Chi 等人 2019; Liu 等人 2024）等表示方式重建其单元格结构。多年来，TSR方法迅速发展并经历三个阶段：(1)早期采用基于规则和启发式的方法；(2)基于深度学习的方法；(3)基于大语言模型（LLM）的方法。

20世纪90年代至2010年代的早期研究方法主要依赖细胞边界和排列方式等视觉特征。Pyreddy等人（Pyreddy & Croft, 1997）提出了基于空白区域模式的字符对齐图；Rus等人（Rus & Subramanian, 1997）则提出了类似的空白密度图。此后又出现了多种基于规则或启发式的方法（Itonori, 1993; Kieninger & Dengel, 1999; Shigarov, Mikhailov & Altaev, 2016）。然而这些技术在处理复杂表格布局时始终存在困难，凸显了开发更通用解决方案的必要性。

在深度学习时代，神经网络方法已显著超越早期的文本结构识别（TSR）方法（Hashmi等人，2021）。基于目标检测的方法（Zheng等人，2021; Long等人，2021; Schreiber等人，2017; Raja、Mondal和Jawahar, 2020; Ajayi等人，2024; Anand等人，2023; Gorishniy等人，2021）能够识别图像中的行、列及标题等结构元素。标记语言模型（Zhong、Shafiei-Bavani 和 Jimeno-Yepes, 2020; Nassar等人，2022）则采用受自然语言处理启发的架构，将TSR视为图像到标记语言的转换过程。基于图论的方法（Koci等人，2019、2018; Qasim、Mahmood 和 Shafait, 2019; Xue、Li和Tao, 2019; Chi等人，2019; Liu等人，2024）通过将表格表示为图结构来建模单元格层面的关系。

近年来，大语言模型（LLM）在自然语言相关任务中展现出卓越性能。然而，面向表格数据处理（TSR）的大语言模型仍是一个尚未充分探索的领域，现有研究主要集中在表格理解领域（Zheng等，2024; Li等，2023; Zha等，2023; Su等，2024; Pang等，2024; Sui等，

2024）。周等人（Zhou等，2024）提出的邻域引导工具链推理框架显著提升了基础视觉大语言模型的识别能力。随着更多数据集的涌现，基于大语言模型的方法有望迅速普及，从而充分发挥大型语言模型处理表格数据的潜力。

TSR数据集。表结构识别（TSR）领域的进展主要得益于基准数据集的发布。ICDAR 系列（Göbel等人（2013）；Gao 等人（2017、2019）；Kayal 等人（2021）提供的基于图像的数据集涵盖了表格检测、结构识别及端到端提取任务，其表格图像类型涵盖PDF文件至手写文档等多种形式。

IBM研究院已贡献了多个具有影响力的数据集。PubTabNet（Zhong、ShafieiBavani 和 Jimeno Yepes, 2020）通过使用PubLayNet流程（Zhong、Tang 和 Yepes, 2019）将PMCOA PDF文件中的表格区域转换为HTML格式，专注于TSR研究；FinTabNet（Zheng等人，2021）解决了PubTabNet仅支持TSR且缺乏全页上下文信息及完整表格区域边界框的局限性；此外，SynthTabNet（Nassar等人，2022）进一步整合了PubTabNet、FinTabNet以及TableBank（Li等人，2020b），以突破领域限制并提升结构复杂度。

TableBank（Li等人，2020b）是另一个大规模的TSR数据集。该数据集通过弱监督方式自动从互联网收集的Word和LaTeX文档中提取表格而构建。这种方法利用了这些格式中已嵌入的结构信息，使得数据集能够在无需大量人工标注的情况下大规模构建。因此，TableBank能为TSR模型提供更好的泛化能力，使其更有效地处理多样化的现实世界表格布局。

如表1所示，现有数据集仍存在数据采集流程受限、领域约束性强以及多样性不足等问题。基于单一数据集训练的模型往往难以在其他数据集上实现良好泛化效果，这与表格数据丰富的视觉特征密切相关（Li等，2020a; Somvanshi等，2024）。例如，针对单色表格训练的模型在处理彩色表格时表现较差。经典数据集如UNLV（Cesarini等，2002）和Marmot（Fang等，2012），以及近期数据集如PubTables-1M（Yang等，2023）和TabRecSet（Smock、Pesala与Abraham，2022），要么缺乏数据多样性（Zheng等，2021; Zhong、ShafieiBavani 与 Jimeno Yepes, 2020; Nassar等，2022; Li等，2020b; Cesarini等，2002; Fang等，2012; Yang等，2023），要么未包含明确的表格类型标签（Long等，2021; Smock、Pesala与Abraham，2022）。为解决这些缺陷，我们发布了大规模合成TSR数据集TableNet，并同步推出首个自主表格生成多智能体系统，旨在推动TSR技术的发展。

纯文本LLM图像合成。近期研究鉴于视觉语言数据的缺乏（Cascante-Bonilla等，2022; Johnson-Roberson等，2016），探索利用纯文本LLM为大语言模型生成合成图像，并将该方法应用于图表与问题答案对的生成。（Kahou等，2017; Kafle等，2018）采用少量图表样本及固定的问题答案模板生成图表VQA数据；（Carbune等，2024; Li与Tajbakhsh, 2023）则运用纯文本LLM生成标注数据。

表1: **TSR数据集对比分析**。针对TableBank和SynthTabNet数据集, 我们随机抽取了1000张图像评估色彩多样性, 发现着色图像不足10张, 表明其多样性较弱。而TabRecSet和 WTW 的数据集多样性则源于真实场景中相机拍摄的图像特征。**标注说明:** T: 表格边界框 (支持表格识别); S: 结构标注 (如HTML标签、跨行内容); C: 单元格级标注 (包含边界框及内容); H/X: 最终HTML/XML输出结果或可由S和C重构; V: 数据集中提供的视觉标签 (如简洁性、颜色、边框样式)。**多样性定义:** 若一个表格图像数据集能够支持至少两种不同且具有实际意义的分类标准, 并据此对图像进行系统化分类, 则该数据集被视为具有多样性。这些标准可涵盖结构特征与视觉属性, 从而支持多维度分析与评估。例如, 一种分类标准可基于结构复杂性 (如表格是否包含跨越单元格); 另一种则可基于视觉风格 (包括边框存在与否、背景颜色或水印干扰等因素)。能够同时满足这两种维度要求的数据集, 能为表格结构识别模型的训练与评估提供更全面的支持。

数据集	多样性	注释	领域	收集方法	表格
桌面网络 (我们的)	真	S, C, H, V	电 信 (可 配 置)	请参见图 2	445K
PubTabNet	假的	S, C, H	药物	基于规则的集合	510K
FinTabNet	假的	T, S, C, H	金融	增加	113K
餐桌银行	真	T, H	概要	基于规则的集合	145K
SynthTabNet	真	T, S, C, H	概要	增加	600K
ICDAR 2019	假的	T, X	机构贡献		3K
PubTables-1m	假的	T, S, C, H	药物	基于规则的集合	948K
TabRecSet	真	T, S, C, H	概要	手动标注	38K
WTW	真	S, C	概要	手动标注	14K
SciTSR	假的	T, C	概要	基于规则的收集	15K

这类任务通常涉及问题或描述的生成。近期的研究方法（如 Han 等人 2023 年、He 等人 2024 年、Xia 等人 2024 年及 Yang 等人 2025 年的研究）会生成图表或多种类型的图像数据, 但这些方法依赖大语言模型（LLM）来生成 HTML 代码, 导致整个流程难以控制且更容易产生错误代码。在我们的研究中, 我们设计了一个多智能体系统, 将表格生成过程明确分解为模式规划、布局构建和内容填充三个阶段, 从而实现了对于表格图像合成与文本-视觉关系标注的可控管理。

多智能体表格生成系统

大语言模型在各项任务中均展现出强劲的性能（Jian、Yang和Jiao 2024; Jian等 2025），但在被动预测方面, 其表现并未超越启发式方法或简单智能体工具在HTML结构生成等特定任务中的表现。基于大语言模型的多智能体系统是一种将多个大语言模型与工具使用、规划及记忆等功能相结合的应用系统。大语言模型作为系统的“大脑”，负责与用户交互并执行关键任务：规划功能可将请求分解为可管理的子任务, 由系统逐一解决；同时系统还集成有反思机制以优化执行过程；工具使用功能则使系统能够与外部环境交互并收集必要信息以满足用户需求。由于本系统的运行流程已在图1中清晰展示, 本节将详细阐述这些功能如何整合到我们的表格生成多智能体系统中, 从而实现可配置、领域适应性强且具有语义基础的表格合成能力。

工作流程与核心概念的实现

大语言模型（LLMs） 我们的表格生成系统由三个阶段专用智能体组成, 这些智能体由核心大语言模型协调运作。核心大语言模型负责解析用户请求（如风格、数量及领域要求），并统筹整个工作流程；主题生成大语言模型则根据指定或默认的电信领域生成与之匹配的表格主题, 确保语义相关性；随后, 标题填充大语言模型和正文填充大语言模型分别通过向 <th> 和 <td> 标签中插入内容来完成HTML框架的构建。本系统基于一个开源代码库。¹

规划: 核心LLM作为高级规划模块, 将任务分解为具有明确依赖关系的结构化子任务。接收到请求后, 模式代理会确定表格尺寸及布局参数（包括行/列数量和跨行关联关系），并根据需求调用CSS生成器进行视觉样式设计；随后生成与领域相关的主题内容并构建初始HTML框架结构。在满足所有前置条件后, 系统依次调用头部内容填充模型和主体内容填充模型。最后, 填充代理会对已填充与未填充的HTML代码进行比对以评估结构完整性, 若检测到错误则选择性重新生成HTML代码。这种多步骤、基于反馈的处理流程确保了表格合成过程的稳健性和可控性。

工具使用为支持多步骤执行, 该系统集成了多个工具模块：(1)CSS样式生成器；(2)用于指定尺寸和跨度的HTML标签生成器；(3)结构验证器, 可构建矩阵表示形式。

¹<https://github.com/WenmuZhou/TableGeneration/tree/main>依据 MIT 许可证。

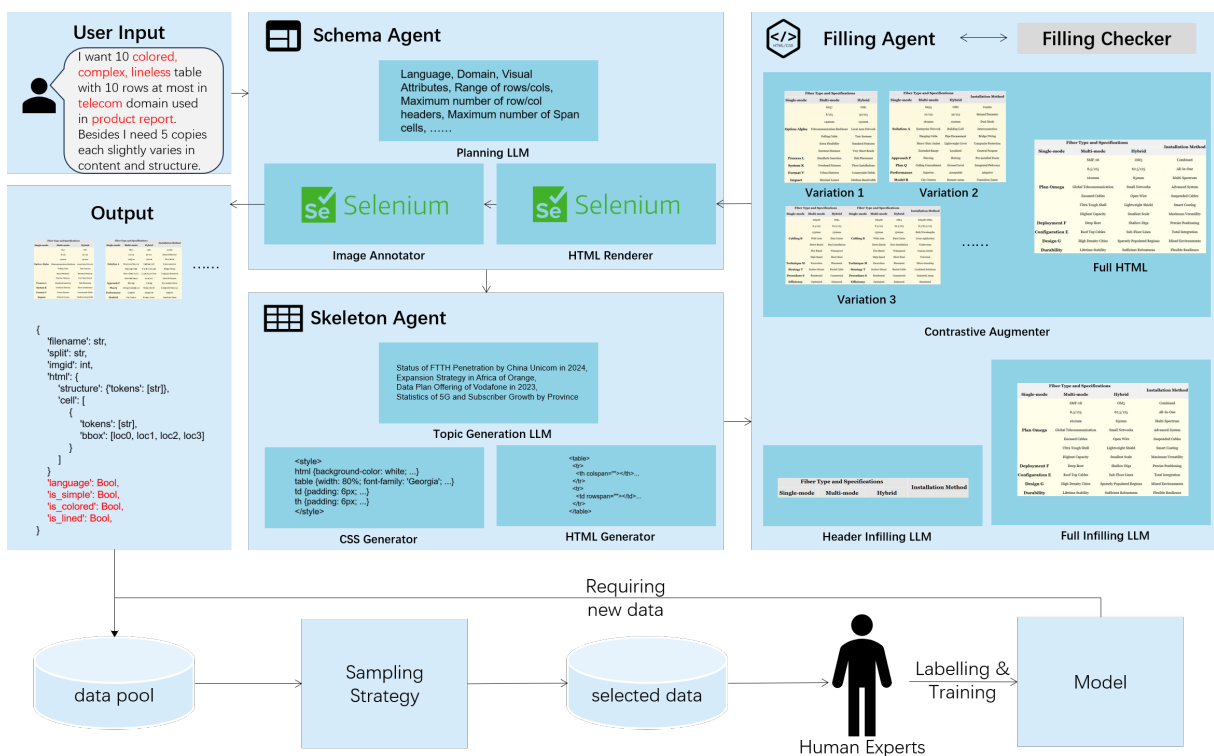


图1：我们多智能体系统的运行流程。

(1) 检查行是否对齐；(2) 用于生成符合规范表格的备用HTML构建器；(3) 用于渲染表格图像并生成注释的Selenium工具。

内存该系统采用两级内存机制：外部内存保存核心大语言模型与用户之间的多轮对话历史，确保对话连贯性与优化效果；内部内存则记录已生成的表格主题，避免重复并提升语义多样性。这两部分内存协同作用，显著提升了交互质量与生成内容的多样性。

在填充组件模块中，我们采用了受对比学习启发的增强策略（Le-Khac、Healy 和 Smeaton, 2020）来提升TableNet模型的多样性和鲁棒性。我们定义了四种变换操作——复制、删除、交换和修改——分别应用于行/列或区块层面：复制可插入重复内容；删除仅在保持结构有效性的情况下移除元素；交换可调换行/列或区块位置；修改则调整行级背景颜色。针对每个HTML结构，体填式大语言模型会生成多种内容变体（包含五种未变换版本和四种变换版本），每种变体均对应特定操作。系统会检测横跨行与列的区域以防止无效修改。这种增强方式不仅提升了模型多样性，还能帮助其精准识别细微的结构差异。为验证生成表格的质量，我们设计了一种混合策略填充检查器，用于评估结构正确性、主题相关性及语义一致性：结构正确性通过验证有效性（图3）和HTML标签误用情况的启发式方法进行评佔；主题相关性和语义一致性则由大语言模型进行排序

评估。我们已验证该填充检查器可替代经过充分训练的人工评分员。

生成数据后，我们进一步利用这些数据在主动学习框架下对TSR模型进行微调。这一人工参与环节可随时启用，因为数据集既包含已标注的生成表格，也包含未标注的真实世界表格——后者对提升TSR性能更具价值。我们首先采用采样策略筛选出具有信息价值的样本，随后将其提交给专家进行高质量标注并用于后续训练。

数据集的收集与构成

我们的数据集源自三个不同的来源：

(1) 包括(1)智能体自动生成的表格、(2)从电信相关PDF文档中抓取的表格，以及(3)从Word文档中抓取的表格，同时包含增强型开源HTML表格数据。这三种数据源分别代表智能体生成、人工标注和基于规则生成。详细的数据集构成详见第节。数据处理流程及最终标注格式如图2所示。图4还展示了表格示例。

代理生成流程。我们采用了八向并行生成策略，每个生成过程对应三种二元属性（简单型、彩色型、带线型）的独特组合。在六天内，我们共生成了约7.5万张中文表格和3.4万张英文表格，目前数量已扩展至44.5万张。为提升真实感，我们重点追求结构完整性、语义准确性和视觉一致性：在结构层面，我们归纳了八种复杂的




图2：数据收集流程。从上至下依次为：智能体生成、网络爬取和开源数据增强。**Anno**

位置说明：用于简单表示表格是否包含跨区域的单元格；颜色选项用于指定表格是否包含背景色、彩色边框或非黑色字体色；线条设置用于定义单元格边框是否完全显示——仅含水平线或垂直线的表格被视为无线条。

业务分类		用户数 (百万)	收入 (亿元)	同比增长率 (%)	市场占有率 (%)	毛利率 (%)	净利润 (亿元)		
移动通信	移动	950	50	4800	6.5	42	35	1700	850
	宽带	220	120	2600	8.2	48	40	1050	420
国际业务	国际	30	350	1050	7.1	18	50	930	265
	数字化	60	100	600	9.4	32	45	275	130

年度经营与目标												
Q1		运营核心指标及 110个重点任务		75		75		60	400	400		
H1		70		31		320		68		200	2500	
Q2		业务增长/用户增长		新增客户/服务		提升客户满意度		80		600	2000	
H2		30		10		60		70		80	600	
全年		75		31		60		400		75	800	800

图 3：无效表格

我们的系统全面支持基于方向的无跨度表格、多级标题以及正文级别的跨度设置。从语义层面而言，我们能够捕捉不同场景下的复杂性差异（例如技术对比与财务报告），其内容校验功能可通过检测标题与正文不匹配或异常现象来提升真实性；在视觉呈现方面，我们利用CSS启发式算法调控边框厚度、线条样式、字体及背景颜色，并综合考虑分辨率变化和水印噪声等次要因素。

PDF与Word文档的爬取及标注流程。鉴于中国电信、中国移动、中国联通和中国宽带网在中国电信行业占据主导地位，我们使用Selenium构建了将这些公司名称与电信相关关键词（如FTTH、数据套餐等）结合的查询语句，并将结果限定为PDF或Word文件。对于PDF文件，由于缺乏可靠的自动提取工具，我们在30天内使用PPOCRLabel手动裁剪并标注了2,700份表格。对于Word文档，则利用其压缩XML结构提取表格标记，将其转换为HTML格式，通过我们的生成器应用CSS样式、渲染图像并获取标注信息，尽管Word文件数量有限，仍成功提取出600份表格。

开源数据集增强流程。由于表格理解模型通常以结构化格式（如HTML/Markdown）作为输入，我们将这些结构化输入视为输出结果，并采用与Word流程相同的处理流程生成图像和标注。基于TABMWP（Lu等人，2022），我们生成了1000个增强型表格。然而，单纯的增强方法存在数据可用性受限、可控性不足以

及领域范围、结构形式和视觉风格可变性有限等局限性。

实验

多样性与填充校验分析

行业多样性验证。为验证我们的多智能体系统生成跨领域表格的能力，我们从《全球行业分类标准》（GICS）中选取了涵盖8个行业的16个领域，计算了我们的自动填充检测器与经过专业训练的人类评分员之间的斯皮尔曼相关系数、皮尔逊相关系数及肯德尔 τ 值。此外，我们重复该流程三次并计算标准差以确保结果的稳定性。根据（Zhang等，2019）的研究表明，我们的自动填充检测器能够有效替代经过专业训练的人类评分员，从而证明其具备语义一致性和跨领域表格生成能力。详细结果详见补充材料。

在大多数领域中，相关性指标始终保持较高水平（多数超过0.8）。此外，我们还评估了系统在表2中针对结构、主题及语义方面存在偏差时修正表格所需的平均迭代次数及相关指标。结果表明：1）各语言组内部均存在强烈的语义一致性；2）填空检测器完全能够替代经过专业训练的人工评分系统进行排序（Zhang et al., 2019）。本实验不仅深入揭示了工业级表格数据中的语义连贯性特征，更为后续双语对齐或领域适配型表格生成研究提供了实证依据。

样式多样性与真实性。通过观察我们抓取的真实场景表格，我们总结出决定表格整体真实性的若干关键因素。Figure 5展示了TableNet可配置样式的分布情况。如第节所述，我们的系统能够生成多种类型的表格。为详细评估表格多样性，我们分析了表格线条样式及结构复杂度的分布特征：补充材料（a）所示图示为复杂彩色线条垂直表格（b）；复杂无条纹斑马线矩阵

Technology	Performance Metrics				
	Speed (Mbps)	Latency (ms)	Bandwidth (GHz)	Range (km)	Reliability (%)
5G NR	1000	10	10	2	99.99
DSL	100	50	1	5	99.5
Fiber Optic	5000	5	20	80	99.9
Wi-Fi 6	3000	20	8	1	99.7
Satellite	100	500	0.5	35000	98.5
LTE	150	30	5	10	99.6
Li-Fi	7000	3	15	10	99.8
Bluetooth 5	50	50	2	0.1	95

TableNet: A Comprehensive Dataset for Table Understanding and Generation									
Category	Table ID	Table Title	Table Content	Table Structure	Table Style	Table Complexity	Table Size	Table Type	Table Source
Table 1	101	Table 1.1	Table 1.1 Content	Table 1.1 Structure	Table 1.1 Style	Table 1.1 Complexity	Table 1.1 Size	Table 1.1 Type	Table 1.1 Source
	102	Table 1.2	Table 1.2 Content	Table 1.2 Structure	Table 1.2 Style	Table 1.2 Complexity	Table 1.2 Size	Table 1.2 Type	Table 1.2 Source
	103	Table 1.3	Table 1.3 Content	Table 1.3 Structure	Table 1.3 Style	Table 1.3 Complexity	Table 1.3 Size	Table 1.3 Type	Table 1.3 Source
	104	Table 1.4	Table 1.4 Content	Table 1.4 Structure	Table 1.4 Style	Table 1.4 Complexity	Table 1.4 Size	Table 1.4 Type	Table 1.4 Source
Table 2	201	Table 2.1	Table 2.1 Content	Table 2.1 Structure	Table 2.1 Style	Table 2.1 Complexity	Table 2.1 Size	Table 2.1 Type	Table 2.1 Source
	202	Table 2.2	Table 2.2 Content	Table 2.2 Structure	Table 2.2 Style	Table 2.2 Complexity	Table 2.2 Size	Table 2.2 Type	Table 2.2 Source
	203	Table 2.3	Table 2.3 Content	Table 2.3 Structure	Table 2.3 Style	Table 2.3 Complexity	Table 2.3 Size	Table 2.3 Type	Table 2.3 Source
	204	Table 2.4	Table 2.4 Content	Table 2.4 Structure	Table 2.4 Style	Table 2.4 Complexity	Table 2.4 Size	Table 2.4 Type	Table 2.4 Source
Table 3	301	Table 3.1	Table 3.1 Content	Table 3.1 Structure	Table 3.1 Style	Table 3.1 Complexity	Table 3.1 Size	Table 3.1 Type	Table 3.1 Source
	302	Table 3.2	Table 3.2 Content	Table 3.2 Structure	Table 3.2 Style	Table 3.2 Complexity	Table 3.2 Size	Table 3.2 Type	Table 3.2 Source
	303	Table 3.3	Table 3.3 Content	Table 3.3 Structure	Table 3.3 Style	Table 3.3 Complexity	Table 3.3 Size	Table 3.3 Type	Table 3.3 Source
	304	Table 3.4	Table 3.4 Content	Table 3.4 Structure	Table 3.4 Style	Table 3.4 Complexity	Table 3.4 Size	Table 3.4 Type	Table 3.4 Source
Table 4	401	Table 4.1	Table 4.1 Content	Table 4.1 Structure	Table 4.1 Style	Table 4.1 Complexity	Table 4.1 Size	Table 4.1 Type	Table 4.1 Source
	402	Table 4.2	Table 4.2 Content	Table 4.2 Structure	Table 4.2 Style	Table 4.2 Complexity	Table 4.2 Size	Table 4.2 Type	Table 4.2 Source
	403	Table 4.3	Table 4.3 Content	Table 4.3 Structure	Table 4.3 Style	Table 4.3 Complexity	Table 4.3 Size	Table 4.3 Type	Table 4.3 Source
	404	Table 4.4	Table 4.4 Content	Table 4.4 Structure	Table 4.4 Style	Table 4.4 Complexity	Table 4.4 Size	Table 4.4 Type	Table 4.4 Source

Region	Technology Type	Infrastructure Status	Service Provider
North America	Fiber Optic	Operational	Provider A
Asia-Pacific	DSL	Under Development	Provider B
Europe	Cable Broadband	Maintenance	Provider C
Africa	Satellite	Planned	Provider D
South America	FTTH	Operational	Provider E
Middle East	LTE	Under Testing	Provider F
Australia	ACN	Decommissioned	Provider G
India	5G NR	Expansion Phase	Provider H
China	Hybrid Fiber-Copper	Stable	Provider I
Japan	Wireless	Emerging	Provider J

Table ID	Table Title	Table Content	Table Structure	Table Style	Table Complexity	Table Size	Table Type	Table Source
101	Table 1.1	Table 1.1 Content	Table 1.1 Structure	Table 1.1 Style	Table 1.1 Complexity	Table 1.1 Size	Table 1.1 Type	Table 1.1 Source
102	Table 1.2	Table 1.2 Content	Table 1.2 Structure	Table 1.2 Style	Table 1.2 Complexity	Table 1.2 Size	Table 1.2 Type	Table 1.2 Source
103	Table 1.3	Table 1.3 Content	Table 1.3 Structure	Table 1.3 Style	Table 1.3 Complexity	Table 1.3 Size	Table 1.3 Type	Table 1.3 Source
104	Table 1.4	Table 1.4 Content	Table 1.4 Structure	Table 1.4 Style	Table 1.4 Complexity	Table 1.4 Size	Table 1.4 Type	Table 1.4 Source

(c)；简单彩色线条垂直表格 (d)；简单带条纹斑马线水平表格。表表表

图 4：TableNet 中的示例




图 5：生成数据的构成

表2：人类与填充检查器等级之间的相关性。Struct.和Sem.分别代表结构和语义。

复杂性	昏暗的.	Avg Iters	矛.	梨.	肯.
简单；朴素	结构；构造。	1.03	0.8203	0.8111	0.7928
	话题	1.07	0.8004	0.8085	0.6990
	Sem.	1.03	0.9253	0.8914	0.8522
复杂的	结构；构造。	1.11	0.8826	0.8751	0.8832
	话题	1.08	0.7352	0.7408	0.6457
	Sem.	1.17	0.8753	0.8411	0.8019

表明我们的TableNet涵盖了现有TSR数据集因采集方法局限性而无法覆盖的大部分分类类别。

使用大语言模型进行实验

我们采用TEDS（基于树编辑距离的相似性度量）（Nassar等人，2022年）作为评估指标。为验证TableNet模型的有效性，我们在包含约48,000张表格的TableNet中文训练集上使用Qwen2-VL-2B进行了微调实验。全参数训练过程采用2块 NVIDIA 4090 RTX GPU完成，批量大小设为1，学习率设为1e-4。模型训练共2个周期，整个训练过程耗时约8小时。本研究的训练集划分、测试集划分及对应子集数据也将公开提供。作为基线模型，我们选取了大规模多模态大语言模型：Qwen2-VL-72B（Wang等人，2024年）、GPT（Achiam等人，2023年）、Claude（Anthropic，2024年）以及 Grok（xAI，2024年）系列模型。为避免提示设计不准确可能带来的负面影响，我们通过整合部分训练样本对Qwen2-VL-72B模型应用了一样本和五样本上下文学习方法。

表4总结了实验结果。基于TableNet训练的模型在多种表格风格下均展现出强劲且稳定的性能；而所有基线模型在简单结构与复杂结构之间均存在明显的性能

差异（见表3：基于不同现有数据集训练的模型在未见过的真实世界数据上的TSR性能）。

资料组	TEDS
桌面网络（我们的）	0.7403
PubTabNet	0.5041
FinTabNet	0.4495
SynthTabNet	0.5242
餐桌银行	0.5401

颜色与无色布局、带线条与无线条设计之间的对比进一步表明：表格多样性给模型泛化能力带来显著挑战，同时也凸显了可控生成能力和详细标注的重要性。结构复杂性——尤其是行/列跨度——仍是最大的难点，因为它需要精确的空间和层次推理能力。我们优化后的Qwen2-VL-2B（FT）模型显著缩小了这一差距，在处理复杂结构时表现优于大型模型；颜色变化同样影响性能：彩色表格虽能提供更丰富的上下文信息但变异性更高，而Qwen2-VL-2B（FT）仍保持稳定表现（0.874 vs. 0.892），相比之下零样本/少量样本训练的大规模LLM模型波动更为明显；线条存在与否则进一步考验模型推断隐含结构的能力——我们的模型依然保持稳定的准确率。总体而言，即便是最先进的LLM模型在缺乏目标监督的情况下也难以表现优异，这凸显了为文本结构识别任务进行结构化训练的必要性。

为更直观地对比该模型与其他现有数据集的性能差异，我们采用爬取的真实世界表格作为测试集，在保持样本数量和训练参数完全一致的前提下，对Qwen2-VL-2B模型在现有数据集上进行微调；同时另单独使用排除爬取数据后的TableNet数据集对其进行微调。随后我们在涵盖多种结构特征、语义表达及视觉风格的未见真实世界表格上评估模型性能。结果显示：基于TableNet数据集训练的模型取得了0.7403的TEDS分数，显著优于其他训练模型，充分证明TableNet数据集具备卓越的真实世界泛化能力。具体结果详见表3。

消融研究

基于大语言模型（LLM）的数据生成常存在结构不稳定性问题，因此我们采用仅基于结构的TEDS方法（Zhong、Shafiei-Bavani和Jimeno-Yepes，2020）来评估LLM的端到端表格合成能力。对于简单表格而言，

表4: TableNet及各子集上HTML的TEDS值。

模型	所有	很简单。		是彩色的。		表面有衬里；	
		简单：朴素	复杂的	彩色	无色	有衬里：带有内层	减少行数
Qwen							
Qwen2-VL-2B(FT)	0.877	0.860	0.912	0.874	0.892	0.891	0.861
Qwen2-VL-72B	0.721	0.822	0.604	0.726	0.713	0.711	0.729
Qwen2-VL-72B（单次训练）	0.696	0.834	0.587	0.706	0.685	0.699	0.695
Qwen2-VL-72B（5次训练）	0.688	0.791	0.576	0.695	0.682	0.689	0.687
GPT							
GPT-4.5-preview	0.614	0.872	0.494	0.732	0.501	0.591	0.634
GPT-4o全版	0.672	0.794	0.487	0.690	0.655	0.664	0.687
克劳德							
克劳德十四行诗第四首	0.620	0.904	0.517	0.687	0.533	0.621	0.618
克劳德十四行诗第四首——思考篇	0.706	0.917	0.561	0.693	0.719	0.749	0.648
克劳德作品集第4卷	0.691	0.921	0.523	0.704	0.675	0.722	0.661
Grok							
Grok-4	0.697	0.892	0.538	0.731	0.642	0.678	0.707

表5: 使用仅基于结构的HTML TEDS序列（由LLM通过直接提示生成）的序列一致性表。文本末尾的小段文字表明LLM填充过程引入了TEDS结构不一致性，该数值最低。

方法	简单：朴素		复杂的	
	和	缺乏	和	缺乏
Qwen2.5	0.954	0.978	0.782	0.835
DeepSeek-R1	0.938	0.974	0.940	0.901
GPT-4o	0.980	0.978	0.931	0.928
代理工具	1 -0.004	1 -0.003	1 -0.012	1 -0.009

我们要求大语言模型（LLM）生成具有指定行数/列数的HTML表格；对于复杂表格，我们还提供了难以用自然语言表述的明确行跨度与列跨度矩阵。如表5所示，即使在简单场景下，LLM也常常无法准确复现表格结构；而基于规则的HTML生成方法则能可靠地生成正确布局，并通过可控提示避免结构失真。这些结果表明：相较于直接使用LLM生成表格，仅在适当时机调用LLM的智能体能够实现更为稳定且精准的结构生成。

为评估基于智能体的设计方法是否能提升数据集质量，我们对近期开发的CoSyn表格图像与问答生成流程（Yang et al., 2025）进行了评估。使用该流程生成的1,000张表格中，仅85张包含合并行/列等复杂结构；其余大多采用简单的堆叠<tr><td>格式。我们还评估了颜色与线条样式多样性，结果如图6所示。

在优化HTML提示以增强结构复杂性后，改进后的基准方




图6: 与现有的CoSyn流程（一种LLM端到端方法）相比。中间子图中，H表示水平线分隔，V表示垂直线分隔。

案在我们的验证工具中获得了平均4.31分（满分5分）的结构评分；相比之下，基于智能体的处理流程平均得分达4.79分，并且每个样本仅需1.11次回退迭代即可生成结构正确的表格。

主动学习TSR实验

主动学习流程的具体步骤如下：我们采用多智能体系统来生成新的数据实例及其对应标签，而不仅限于从未标注集 U 中随机选取。大型语言模型在整个主动学习循环中发挥着关键作用——首先通过标注初始数据集（ $\mathcal{L}_{init}$ ）来解决冷启动问题；在查询阶段，从 U 中筛选出具有信息价值的实例；这些实例随后在标注阶段被自动或人工完成标注；新标注的数据会被加入已标注集 L ，并更新目标模型 f_θ 。该过程将持续迭代直至达到预设的标注预算要求。此方法通过利用大型语言模型进行数据生成、借助自动化标注工具完成标注任务，有效降低了对人工标注者的依赖，从而克服了传统主动学习中的诸多挑战。

算法1: 主动学习

```
1: Input: Unlabeled dataset  $\mathcal{U}$ , Model  $M$ , Budget  $k$ 
2: Output: Trained model  $f_\theta$ , Labeled dataset  $\mathcal{L}$ 
3:  $\mathcal{L}_{init}, \mathcal{U} \leftarrow \text{Initialize}$ 
4:  $f_\theta \leftarrow \text{Train}(\mathcal{L}_{init})$ 
5: while not Stop( $k, f_\theta, M$ ) do
6:    $x \leftarrow \text{Query}(f_\theta, \mathcal{U}, M)$ 
7:    $(x, y) \leftarrow \text{Annotate}(x, M)$ 
8:   if  $x \in \mathcal{U}$  then  $\mathcal{U} \leftarrow \mathcal{U} \setminus \{x\}$ 
9:    $\mathcal{L} \leftarrow \mathcal{L} \cup \{(x, y)\}$ 
10:   $f_\theta \leftarrow \text{Train}(\mathcal{L})$ 
11: end while
12: return  $f_\theta^*, \mathcal{L}$ 
```

算法2: k-中心贪心算法

```
1: 输入: 数据点  $\{x_i\}_{i=1}^n$  初始集合  $s_0$ , 预算  $b$  2: 输出:  $s$ 
3:  $s \leftarrow s_0$ 
4: 重复
5:  $u \leftarrow \arg \max_{i \in [n] \setminus s} \min_{j \in s} \Delta(x_i, x_j)$ 
6:    $s \leftarrow s \cup \{u\}$ 
7: 直至  $|s| = b$ 
8: 返回  $s$ 
```

基于Qwen2-VL-2B (FT) (以下简称基础模型), 我们采用基于多样性的策略进行了主动学习微调研究, 因为TableNet在行/列数量、合并单元格位置、颜色等方面均表现出多样性。训练使用了2块 NVIDIA RTX 4090 GPU, 并采用LoRA方法进行1个周期的微调; TEDS作为评估指标。我们采用了CoreSet方法 (Sener和Savarese 2017), 即算法2所示的贪心k中心聚类算法: 通过选择 b 个中心点, 使数据点与其最近中心点之间的最大距离最小化, 其数学模型可表述如下: s_0 表示未标注数据集, b 为标注预算, s_1 代表用于标注的样本集合。

$$\min_{s_1: |s_1|=b} \max_{i \in [n] \setminus s_1} \min_{j \in s_1} \Delta(x_i, x_j). \quad (1)$$

我们将其作为算法1所示的查询策略, 并与随机采样 (RSB)、困难样本挖掘 (HE) (Liu等人, 2025; Shrivastava, Gupta和Girshick, 2016) 以及基于困惑度的不确定性采样 (PPL) 进行了比较。我们从基础模型的视觉塔中提取了修补后的视觉嵌入 $e \in \mathbb{R}^{patch \times dim}$, 并将其最大池化与均值池化的嵌入向量拼接为向量 $c \in \mathbb{R}^{2 \times dim}$ 以实现该方法。

如图7所示, 基于多样性分析的CoreSet方法始终展现出优于各类基线方法 (包括随机采样、基于困惑度的不确定性采样以及困难样本挖掘) 的稳定性能。此外, 通过对比相同性能水平下的训练样本数量可以发现: 在低数据量场景和标准数据量场景下, 主动学习方法不仅与基线方法表现相当, 还能将所需样本量至




图 7: TSR 实验结果

少减少50%。例如, 在使用1万份主动选取样本进行模型微调时, 其TEDS性能可达约0.973; 而其他基线方法则需要超过2万甚至4万份训练样本。

局限性

尽管我们的系统支持可配置参数, 但仍受限于底层大语言模型 (LLM) 的预训练分布特征及推理能力。因此, 生成内容的多样性可能无法完全涵盖边缘场景或高度领域特定化的表格格式; 此外, 由于模型对用户指定领域和语言的理解存在差异, 生成的表格图像质量也可能参差不齐, 导致表格内容与语义内容不一致或完全无关。

结论

在本研究中, 我们推出了TableNet——一个主要源自自主生成技术的新型TSR数据集。为完善该数据集, 我们开发了首个自主表格生成与识别多智能体系统, 该系统不仅支持TSR任务, 还能通过用户自定义参数实现可控的表格合成与自动标注功能。该系统具备可扩展性、灵活性及科研导向的数据构建特性, 并展现出高效生成大量结构可靠表格的能力。我们的数据采集流程具有高度可扩展性, 结合实证结果进一步凸显了TableNet及该系统的TSR工具价值。我们认为, 将强大的生成引擎与TableNet相结合必将显著推动TSR领域的发展。

参考文献

- 阿奇亚姆, J.; 阿德勒, S.; 阿加瓦尔, S.; 艾哈迈德, L.; 阿卡亚, I.; 阿莱曼, F. L.; 阿尔梅达, D.; 阿尔滕施密特, J.; 阿尔特曼, S.; 阿纳德卡特, S.; 等。
2023年。GPT-4技术报告。arXiv预印本 arXiv:2303.08774。Ajayi, K.、Zhang, L.、He, Y.与Wu, J. 2024. 表结构识别中的不确定性量化。收录于2024年IEEE数据科学信息重用与集成国际会议 (IRI), 第1–6页。IEEE。
Anand, A.; Jaiswal, R.; Bhuyan, P.; Gupta, M.; Bangar, S.; Imam, M. M.; Shah, R. R.; 及 Satoh, S. 2023.

Tc-ocr: 用于高效检测与识别表格结构及内容的表格结构光学字符识别系统。收录于《首届信息检索深度多模态学习国际研讨会论文集》, 第11-18页。

人形。2024年。Claude 3型号系列系统卡。

贝卢奇 (Beluch, W. H.)、格内温 (Genewein, T.)、诺恩伯格 (Nürnberger, A.) 及Köhler, J. M.

2018. 集合方法在图像分类主动学习中的作用。载于《IEEE 计算机视觉与模式识别会议论文集》, 9368-9377。

Carbune, V.; Mansoor, H.; Liu, F.; Aralikkat, R.; Baechler, G.; Chen, J.; 及 Sharma, A. 2024. 基于图表的推理: 将能力从大型语言模型迁移至小规模语言模型。arXiv预印本 arXiv:2403.12596。

Cascante-Bonilla, P.; Wu, H.; Wang, L.; Feris, R. S.; 及 Ordonez, V. 2022. Simvqa: 探索用于视觉问答的模拟环境。载于《IEEE/ CVF 计算机视觉与模式识别会议论文集》, 第5056-5066页。

Cesarini, F.; Marinai, S.; Sarti, L. 和 Soda, G. 2002. 文档图像中的可训练表格定位。载于《2002年国际模式识别会议论文集》第3卷, 第236-240页。IEEE。

池志; 黄浩; 徐华德; 余浩; 尹伟; 毛晓林。2019年。复杂表格结构识别。arXiv预印本 arXiv:1908.04729。

Fang, J.; Tao, X.; Tang, Z.; Qiu, R. 和 Liu, Y. 2012. 表检测评估所需的数据集、真实标注及性能指标。收录于2012年第10届 IAPR 国际文档分析系统研讨会, 第445-449页。IEEE。

Gal, Y.; Islam, R.; 及 Ghahramani, Z. 2017. 基于图像数据的深度贝叶斯主动学习。载于国际机器学习会议, 第1183-1192页。PMLR。

Gao, L.; Huang, Y.; D'ejean, H.; Meunier, J.-L.; Yan, Q.; Fang, Y.; Kleber, F. 和 Lang, E. 2019. 2019年表格检测与识别竞赛 (cTDaR)。收录于2019年国际文档分析与识别会议 (ICDAR), 第1510-1515页。IEEE。

Gao, L.; Yi, X.; Jiang, Z.; Hao, L. 和 Tang, Z. 2017. ICDAR2017页面对象检测竞赛。收录于《2017年第14届 IAPR 国际文档分析与识别会议 (ICDAR)》第1卷, 第1417-1422页。IEEE。

Gissin, D. 和 Shalev-Shwartz, S. 2019. 区分性主动学习。arXiv预印本 arXiv:1907.06347。

Göbel, M.; Hassan, T.; Oro, E.; 及 Orsi, G. 2013. ICDAR 2013表格竞赛。收录于第十二届文档分析与识别国际会议, 1449-1453页。IEEE。

Gorishniy, Y.; Rubachev, I.; Khrulkov, V. 和 Babenko, A. 2021. 重新审视适用于表格数据的深度学习模型。《神经信息处理系统进展》, 34: 18932-18943。

Han, Y.; Zhang, C.; Chen, X.; Yang, X.; Wang, Z.; Yu, G.; Fu, B.; 及 Zhang, H. 2023. Chartllama: 一种用于图表理解与生成的多模态大语言模型。arXiv预印本 arXiv:2311.16483。Hashmi, K. A.; Liwicki, M.; Stricker, D.; Afzal, M. A.; Afzal, M. A.; 及 Afzal, M. Z. 2021. 基于深度神经网络的文档图像中表格识别现状与性能分析。IEEE Access, 9: 87663-87685。

He, W.; Xi, Z.; Zhao, W.; Fan, X.; Ding, Y.; Shan, Z.; Gui, T.; Zhang, Q.; 和 Huang, X. 2024. 从大语言模型到中等规模语言模型的可视化图表推理能力提升。arXiv预印本 arXiv:2410.18798。Itonori, K. 1993. 基于文本块排列和横线位置的表格结构识别。收录于第二届国际文档分析与识别会议 (ICDAR '93) 论文集, 第765-768页。IEEE。

Jian, C.; Yang, K. 与 Jiao, Y. 2024. 三级导航器: 基于LLM的三级学习框架实现时间序列 OOD 泛化。《神经信息处理系统进展》, 37: 110613-110642。

Jian, C.; Yang, K.; Ouyang, Y. 和 Ye, X. 2025. 大型语言模型的稳定偏好优化: 超越直接偏好优化的双层方法。arXiv预印本 arXiv:2507.07723。Johnson-Roberson, M.; Barto, C.; Mehta, R.; Sridhar, S. N.; Rosaen, K.; Vasudevan, R. 2016. 矩阵驱动: 虚拟世界能否替代人类为现实任务生成的标注? arXiv预印本 arXiv:1610.01983。

Kafle, K.; Price, B.; Cohen, S. 和 Kanan, C. 2018. Dvqa: 通过问答理解数据可视化。载于《IEEE 计算机视觉与模式识别会议论文集》, 第5648-5656页。

Kahou, S. E.; Michalski, V.; Atkinson, A.; K'ad'ar, A.; Trischler, A.; 以及 Bengio, Y. (2017)。Figureqa: 一个带注释的图形数据集。视觉推理。arXiv预印本 arXiv:1710.07300。

Kayal, P.; Anand, M.; Desai, H.; 和 Singh, M. 2021. ICDAR 2021科学表格图像识别至LaTeX竞赛。载于《文档分析与识别——ICDAR 2021: 第16届国际会议》, 瑞士洛桑, 2021年9月5-10日, 会议论文集第四部分第16卷, 754-766页。Springer出版社。

Kieninger, T.; 以及 Dengel, A. 1999. t-recs表格识别与分析系统。载于《文档分析系统: 理论与实践——第三届 IAPR 研讨会论文集》(DAS '98, 日本长野, 1998年11月4-6日), 精选论文第3辑, 255-270页。Springer出版社。

Koci, E.; Thiele, M.; Lehner, W. 和 Romero, O. 2018. 基于图表示法实现电子表格中的表格识别。收录于2018年第13届 IAPR 国际文档分析系统 (DAS) 研讨会, 第139-144页。IEEE。

Koci, E.; Thiele, M.; Romero, O. 和 Lehner, W. 2017. 电子表格中的表格识别与重建。载于《高级信息与系统工程: 第29届国际会议 (CAiSE 2017)》, 德国埃森, 2017年6月12-16日, 论文集第29卷, 527-541页。Springer出版社。

Koci, E.; Thiele, M.; Romero, O. 和 Lehner, W. 2019. 基于遗传学方法的电子表格自适应表格识别研究。收录于2019年国际文档分析与识别会议 (ICDAR), 第1274-1279页。IEEE。

Le-Khac, P. H.; Healy, G.; 及 Smeaton, A. F. 2020. 对比表征学习: 一个框架与综述。Ieee Access, 8: 193907-193934。

Li, K.; Wigington, C.; Tensmeyer, C.; Zhao, H.; Barmpalios, N.; Morariu, V. I.; Manjunatha, V.; Sun, T. 和 Fu, Y. 2020a. 跨域文档对象检测: 基准测试套件与方法。载于IEEE/ CVF 计算机视觉与模式识别会议论文集, 第12915-12924页。

Li, M.; Cui, L.; Huang, S.; Wei, F.; Zhou, M.; 及 Li, Z. 2020b. Tablebank: 基于图像的表格检测与识别基准表。收录于第十二届语言资源与评估会议论文集, 第1918-1925页。

Li, P.; He, Y.; Yashar, D.; Cui, W.; Ge, S.; Zhang, H.; Fainman, D. R.; Zhang, D. 和 Chaudhuri, S. 2023. Table-GPT: 专为多种表格任务优化的GPT模型。arXiv预印本 arXiv:2310.09263。

Li, S.; Tajbakhsh, N. 2023. Scigraphqa: 面向科学图谱的大规模合成多轮问答数据集。arXiv预印本 arXiv:2308.03349。

Liu, H.; Li, X.; Gong, M.; Liu, B.; Wu, Y.;

Jiang, D.; Liu, Y.; 及 Sun, X. 2024. 获取所需内容: 基于

灵活组件推理的复杂表格结构识别方法再探讨。载于《美国人工智能协会人工智能会议论文集》第38卷,第3603–3611页。

Liu, L.; Liang, Y.; Yan, X.; Huangfu, L.; Samtani, S.; Yu, Z.; Zhang, Y.; Zeng, D. D. 2025. 硬样本挖掘: 高效且稳健的模型训练新范式。《IEEE神经网络与学习系统汇刊》。

Long, R.; Wang, W.; Xue, N.; Gao, F.; Yang, Z.; Wang, Y.; 及 Xia, G. -S. 2021. 野生环境中的表格结构解析. 收录于《IEEE/CVF 国际计算机视觉会议论文集》,第944–952页。

Lu, P.; Qiu, L.; Chang, K. -W.; Wu, Y. N.; Zhu, S. -C.; Rajpurohit, T.; Clark, P.; 及Kalyan, A. 2022. 基于策略梯度的动态提示学习在半结构化数学推理中的应用。arXiv预印本 arXiv:2209.14610。

Nassar, A.、Livathinos, N.、Lysak, M. 和 Staar, P. 2022. Tableformer: 基于Transformer的表格结构理解。载于《IEEE/CVF 计算机视觉与模式识别会议论文集》,第4614–4623页。

Pang, C.、Cao, Y.、Yang, C. 和 Luo, P. 2024. 揭示大型语言模型在表格信息检索中的局限性。arXiv 预印本 arXiv:2406.04113。

Pyreddy, P.; 以及 Croft, W. B. 1997.《Tintin: 一种文本表格检索系统》。载于第二届ACM数字图书馆国际会议论文集,第193–200页。

Qasim, S. R.; Mahmood, H.; 及Shafait, F. 2019. 基于图神经网络的表格识别方法再探讨。载于2019年国际文档分析与识别会议 (ICDAR),第142–147页。IEEE。

Raja, S.; Mondal, A.; 及Jawahar, C. 2020. 基于自上而下与自下而上线索的表格结构识别。载于《计算机视觉——ECCV 2020: 第16届欧洲会议》,英国格拉斯哥,2020年8月23–28日,会议论文集, XXVIII 部分第16卷,第70–86页。Springer出版社。

Rus, D. 与Subramanian, D. 1997. 信息捕获与访问的定制化设计。《ACM信息系统汇刊 (TOIS)》,15(1): 67–101。

Schreiber, S.; Agne, S.; Wolf, I.; Dengel, A.; 及 Ahmed, S. (2017)。《Deepdesrt: 用于文档图像中表格检测与结构识别的深度学习方法》。收录于2017年第14届 IAPR 国际文档分析与识别会议 (ICDAR) 第1卷,第1162–1167页。IEEE。

Sener, O. 和 Savarese, S. 2017. 卷积神经网络的主动学习: 核心集方法。arXiv预印本 arXiv:1708.00489。

Shigarov, A.; Mikhailov, A.; 及 Altaev, A. 2016. 未标记 PDF 文档中的可配置表格结构识别。载于《2016年ACM文档工程研讨会论文集》,第119–122页。

Shrivastava, A.、Gupta, A. 和 Girshick, R. 2016. 基于在线困难样本挖掘的区域目标检测器训练方法。载于《IEEE 计算机视觉与模式识别会议论文集》,第761–769页。

Smock, B.、Pesala, R. 和 Abraham, R. 2022. PubTables-1M: 实现从非结构化文档中全面提取表格。收录于IEEE/CVF 计算机视觉与模式识别会议论文集,第4634–4642页。

Somvanshi, S.; Das, S.; Javed, S. A.; Antariksa, G. 和 Hossain, A. 2024. 关于深度表格学习的综述。arXiv 预印本 arXiv:2410.12034。

Su, A.; Wang, A.; Ye, C.; Zhou, C.; Zhang, G.; Chen, G.; Zhu, G.; Wang, H.; Xu, H.; Chen, H.; 等人, 2024. Tablegpt2: 一个具备表格数据集成功能的大型多模态模型。arXiv预印本 arXiv:2411.02059。

Sui, Y.、Zhou, M.、Zhou, M.、Han, S. 和 Zhang, D. 2024. Table meets llm: 大型语言模型能否理解结构化表格数据? 一项基准测试与实证研究。载于第17届ACM国际网络搜索与数据挖掘会议论文集,第645–654页。

Wang, P.; Bai, S.; Tan, S.; Wang, S.; Fan, Z.; Bai, J.; Chen, K.; Liu, X.; Wang, J.; Ge, W.; 等人, 2024. Qwen2-vl: 增强视觉语言模型在任意分辨率下的世界感知能力。arXiv预印本 arXiv:2409.12191。

xAI. 2024年。Grok-1型号卡片。

Xia, R.; Zhang, B.; Ye, H.; Yan, X.; Liu, Q.; Zhou, H.; Chen, Z.; Ye, P.; Dou, M.; Shi, B.; 等人, 2024. Chartx & chartvlm: 一个用于复杂图表推理的多功能基准模型与基础模型。arXiv预印本 arXiv:2402.12185。

Xia, Y.; Mukherjee, S.; Xie, Z.; Wu, J.; Li, X.; Apon-te, R.; Lyu, H.; Barrow, J.; Chen, H.; Dernoncourt, F.; 等人, 2025. 从选择到生成: 基于LLM的主动学习综述。载于《计算语言学协会第63届年会论文集 (第一卷: 长论文)》,第14552–14569页。

Xue, W.; Li, Q.; 及Tao, D. 2019. Res2tim: 从表格图像中重建句法结构。收录于2019年文档分析与识别国际会议 (ICDAR),第749–755页。IEEE。

Yang, F.; Hu, L.; Liu, X.; Huang, S.; 及Gu, Z. 2023. 用于大规模自然环境下的端到端表格识别的大规模数据集。Scientific Data, 10(1): 110。

Yang, K.; Ren, J.; Zhu, Y.; 及Zhang, W. 2018. 无线物联网入侵检测中的主动学习。IEEE无线通信, 25(6): 19–25。

Yang, Y.; Patel, A.; Deitke, M.; Gupta, T.; Weihs, L.; Head, A.; Yatskar, M.; Callison-Burch, C.; Krishna, R.; Kembhavi, A.; 和 Clark, C. 2025. 基于代码引导的合成多模态数据生成实现文本丰富图像理解的规模化扩展。载于Che, W.; Nabende, J.; Shutova, E.; 与 Pilehvar, M. T. 编,《第63届计算语言学协会年会论文集 (第一卷: 长论文)》,第17486–17505页。奥地利维也纳: 计算语言学协会。ISBN 979-8-89176-251-0。

Yoo, D.; Kweon, I. S. 2019. 主动学习中的学习损失。载于《IEEE/CVF 计算机视觉与模式识别会议论文集》,第93–102页。

Zha, L.; Zhou, J.; Li, L.; Wang, R.; Huang, Q.; Yang, S.; Yuan, J.; Su, C.; Li, X.; Su, A.; 等人, 2023. TableGPT: 致力于将表格、自然语言和命令整合为单一的GPT模型。arXiv预印本 arXiv:2307.08674。

张, T.; 基肖尔, V.; 吴, F.; 温伯格, K. Q.; 以及阿尔齐, Y. 2019年。Bertscore: 使用BERT评估文本生成。arXiv预印本 arXiv:1904.09675。

Zheng, M.; Feng, X.; Si, Q.; She, Q.; Lin, Z.; Jiang, W. 和 Wang, W. 2024. 多模态表格理解。arXiv 预印本 arXiv:2406.08100。

郑, X.; 伯迪克, D.; 波帕, L.; 钟, X.; 以及王, N. X. R. 2021年。全球表格提取器 (gte): 一种利用视觉上下文实现表格联合识别与单元格结构识别的框架。载于《IEEE/CVF 计算机视觉应用冬季会议论文集》,第697–706页。

Zhong, X.; ShafieiBavani, E.; 和 Jimeno Yepes, A. 2020. 基于图像的表格识别: 数据、模型与评估。载于《欧洲计算机视觉会议》,第564–580页。Springer出版社。

Zhong, X.、Tang, J. 和 Yepes, A. J. 2019. Publaynet: 史上规模最大的文档布局分析数据集。收录于2019年国际文档分析与识别会议 (ICDAR),第1015–1022页。IEEE。

周宇；程明；毛强；刘强；徐峰；李晓；陈恩。
2024年。基于视觉大语言模型的 Enhancing Table 识别：基准测试与邻域引导工具链推理器。*arXiv预印本 arXiv:2412.20662*。
Zhu, Y.; Yang, K. 2019. 用于交互式异常检测的三元主动学习方法。*IEEE Access*, 7: 63195–63203。

补充实验结果

针对多个行业的实验研究

为评估不同全球行业分类标准（GICS）领域及行业中表格的语义一致性，我们对中国与英文表格进行了全面的相关性分析。具体而言，我们在每个行业类别下计算了两种语言对应表格之间的平均成对语义相关系数。所用指标包括斯皮尔曼等级相关系数（Spear.）、皮尔逊相关系数（Pear.）和肯德尔 tau 系数（Ken.），均以均值±半标准差表示以体现统计稳定性。结果见表6。

每个行业均单独进行评估，每行业包含两行数据：第一行为中文表格的语义相关性，第二行为其对应的英文版本。

详细多样性分析

通过对实际表格结构的观察，我们根据行类型将表格分为5种类型，并根据表格标题进一步划分为6种类型。如图8所示，我们的系统能够生成指定类型的表格：其中“全边框”表示每个单元格均具有完整的边框；“水平/垂直无边框”指单元格缺少相应的水平或垂直边框；“带边框标题”仅标题单元格带有边框；“矩阵/竖排/横排表格”则同时具备顶部、左侧或右侧标题。

然而，现有的数据集始终无法涵盖这类表格类型。例如，PubTabNet和FinTabNet的数据均来源于科学文献，主要由仅包含黑白线条的垂直单标题表格构成；而TableBank则主要由带有完整线条的垂直单标题表格组成，这严重影响了模型识别无线条表格的能力。




图 8：TableNet 的详细组成结构

文档爬取关键词

我们使用Selenium以以下格式对微软搜索引擎进行了爬取：

公司简称 + 电信相关关键词 + 文件类型：pdf/doc

关键词列于表7中。

LLM HTML生成提示语

仅基于结构的生成提示

请生成一个包含 {no-of-行} 行和 {no-ofCols} 列、数据为 {content} 的 HTML 表格。序列中仅允许使用 (tr)、<td>、(/tr) 及 </td> 标签。请以以下 JSON 格式返回生成的表格：

```
{ "html" : "HTML表格字符串" }
该表格应包含跨越多行或多列的单元格。以下是两个用于表示行跨度和列跨度的矩阵： 行跨度矩阵: {row_spanmatrix} 列跨度矩阵: {column_spanmatrix}
矩阵: {col-span-matrix}
```

主题生成提示

请提供与 {domain} 领域高度相关的 {lang} 语句 {copy}，每个语句需尽可能详细具体。随后以以下 JSON 格式返回生成的语句： { "phrase" : [phrase1, phrase2, phrase3, phrase4, phrase5] } 已使用以下主题，请勿重复或生成与之高度相似的内容: [已用主题]

HTML头部填写提示

以下是关于 {domain} 领域的 HTML 表格，主题为 {topic}，表格语言为 {lang}。需要填写的 HTML 代码如下： {HTML_CODE}

HTML 表格的结构已完整：头部区域 (<th> 标签) 已包含所有列名称，而主体部分 (<td> 标签) 为空。无需修改原始 HTML 结构、属性或标签，请根据给定的主题及现有标题信息填写表格主体内容 (<td> 标签)。确保表格中的每个单元格均包含独特且有意义的信息。

生成 {copy} 个不同版本的填充 HTML 表格，然后以以下 JSON 格式返回结果： { "html" : "[填充HTML表格列表]" }

LLM实验与少量提示下的学习过程

从图像中读取表格内容，并将其转换为 HTML 表格格式。HTML 代码必须以 (html) (body)(table) 开头，以 (/table)(/body)(/html) 结尾，且整个 HTML 代码需输出为单行。输出结果仅包含以 (html) (body)(table) 开头、以 (/table)(/body)(/html) 结尾的 HTML 代码，不得包含其他任何内容。

示例：HTML1 HTML2 ...

HTML主体填充提示

您将担任严格的 HTML 编辑器，负责处理位于 {domain} 域名下的、主题为 {topic}、使用 {lang} 表格语言的表格。需要填写的 HTML 代码片段如下： {HTML_CODE}

以上为表格标题的原始 HTML 段落。无需修改原始 HTML 结构，请在每个 `<th>` 标签内填写缺失的列名称。

重要规则：

表6：在多个全球行业分类标准（GICS）行业表格中分别添加或减去半个标准差后得出的平均语义相关性。对于每个行业，上方结果线代表中文表格，另一条线代表英文表格。

部门	工业	矛.	梨.	肯。
能量	设备与服务	0.8021 ± 0.015	0.7954 ± 0.007	0.7311 ± 0.007
		0.8204 ± 0.016	0.8080 ± 0.015	0.7551 ± 0.010
	可消耗燃料	0.8344 ± 0.021	0.8047 ± 0.010	0.7612 ± 0.005
		0.8121 ± 0.002	0.7853 ± 0.013	0.7224 ± 0.018
材料	化学品	0.8006 ± 0.017	0.8105 ± 0.015	0.7290 ± 0.022
		0.8788 ± 0.027	0.8446 ± 0.017	0.8054 ± 0.020
	金属与采矿	0.8951 ± 0.027	0.8848 ± 0.028	0.8109 ± 0.019
		0.9091 ± 0.006	0.9004 ± 0.005	0.7923 ± 0.016
医疗保健	生物技术	0.8516 ± 0.016	0.8476 ± 0.015	0.7577 ± 0.015
		0.8607 ± 0.016	0.8394 ± 0.017	0.7509 ± 0.004
	医药品	0.8585 ± 0.007	0.8347 ± 0.010	0.7544 ± 0.008
		0.8433 ± 0.015	0.8172 ± 0.011	0.7712 ± 0.017
金融：财务状况	银行	0.8821 ± 0.018	0.8543 ± 0.019	0.7654 ± 0.009
		0.9007 ± 0.020	0.8687 ± 0.022	0.8147 ± 0.027
	保险	0.7963 ± 0.014	0.7896 ± 0.009	0.7089 ± 0.002
		0.8191 ± 0.011	0.8000 ± 0.004	0.6891 ± 0.008
信息 技术	通信设备	0.8598 ± 0.016	0.8239 ± 0.011	0.7653 ± 0.016
		0.8437 ± 0.022	0.8171 ± 0.011	0.7096 ± 0.001
	半导体设备	0.8243 ± 0.015	0.8145 ± 0.015	0.7505 ± 0.010
		0.8457 ± 0.012	0.8019 ± 0.016	0.7174 ± 0.004
通信服务	电信	0.8826 ± 0.006	0.8224 ± 0.007	0.7338 ± 0.004
		0.8897 ± 0.009	0.8656 ± 0.010	0.7560 ± 0.005
	媒体	0.8537 ± 0.010	0.8348 ± 0.010	0.7299 ± 0.004
		0.8751 ± 0.011	0.8322 ± 0.010	0.7402 ± 0.008
公用事业	电力公司	0.8941 ± 0.009	0.8781 ± 0.06	0.7885 ± 0.002
		0.8656 ± 0.013	0.8346 ± 0.015	0.7750 ± 0.006
	天然气服务	0.8338 ± 0.012	0.7953 ± 0.011	0.7287 ± 0.006
		0.8052 ± 0.013	0.7940 ± 0.012	0.6800 ± 0.008
房地产	股权房地产信托基金	0.8208 ± 0.015	0.7890 ± 0.015	0.6868 ± 0.006
		0.8236 ± 0.014	0.8163 ± 0.005	0.7233 ± 0.003
	管理与发展	0.8277 ± 0.021	0.8134 ± 0.015	0.7358 ± 0.015
		0.8155 ± 0.013	0.8052 ± 0.013	0.6986 ± 0.002

表7：关键词

公司简称		
中国 联通 中国 宽网	中国 电信	中国 手机
与电信相关的关键词		
5G 运算符 千兆比特 服务质量 服务大厅 宽带 物联网 网络安全性 网络覆盖范围 客户联系管理 数据定价	光纤 基点 数据中心 随便走 网络存取 云计算是一种新兴的商业计算模型。它将计算任务分布在大量计算机构成的资源池上。 网关服务 Wi-Fi 存取网络 IPTV VoLTE	电通信 中框网络 FTTR 增值服务 语音服务 局域网 振铃音 核心网 网络最佳化 5G 计划 计划定价

请勿添加、删除或修改任何标签、属性或结构；仅需填写<th>标签的内容——即使<th>标签具有colspan或rowspan属性，仍须为其指定合适的列名称且不得留空；返回格式必须遵循以下JSON结构：

HTML排序提示

您是表格质量评估领域的专家，专长于分析HTML表格的结构、语义及主题相关性。请根据以下输入内容，从多个维度评估该表格的质量，并说明评分的具体理由。

- 维度（1至5，仅限整数）：
- 结构正确性（结构等级）：（评分必须严格为{score}）
该评分仅基于结构指标；细胞含量不影响该评分。
该表格每行的逻辑列数详情如下：
{ 结构信息提示 }。
- 主题相关性（主题排名）：
该方法仅基于表格内容与主题之间的相关性，而忽略表达方式或语义含义。
评估内容是否与主题“{topic}”相符。
确保全面涵盖标题中提及的所有维度（例如：时间、地点、指标、技术、组织），不多也不少。
请检查表格是否包含以下实体信息：{实体提示项}。必须包含这些实体（无论是具体实体还是通用实体）；禁止使用无关或完全不相关的内容；不允许使用虚构或牵强的理由；无需仅依赖关键词的字面出现，与主题内容的语义契合即可。
- 语义一致性（语义等级）：
HTML中是否存在完全空白的单元格？如果是，请建议使用与表格标题内容一致的内容进行填充。
表格标题与正文在语义上是否一致？{复杂字符串2}
标题是否清晰且详细？
是否存在损坏或乱码的字符？
根据出现上述问题的细胞比例扣分。对于孤立问题切勿给出极低分数。“N/A”、“-”或“TBD”等表述均不视为无效值。

- 总分（排名）：
这应是上述三个维度中的最低评分。输出格式必须严格采用JSON格式，不得包含额外文本。
- 主题：{topic}
- 原始HTML表格代码：{html code}

修改后的 CoSyn 提示

您是一位具备广泛领域知识的内容创作专家，请根据以下要求为我撰写相关内容：

- 主题：{topic}
- 图类型：表格
- 请遵循以下要求：
 - 生成的材料应与主题紧密相关，并根据目标受众进行定制。内容结构需适配所指定的图表类型（如表格、图表等）。
 - 所有内容必须真实可信，并使用现实中的实体名称。严禁使用占位符（如xxA、xxB、[姓名]、[日期]等）。
 - 材料应具有多样性，并从不同角度涵盖该主题，以确保信息的丰富性和广度。
 - 控制内容量，仅提供关键信息，确保所有内容均能容纳于单页文档中。
 - 所有内容均须使用英语撰写，即使对象并非英语使用者亦然。
- 请以JSON格式输出，无需添加任何额外说明文字。
您是编写HTML文档方面的专家。
我拥有一个关于{topic}的数据集，可用于生成HTML表格。
数据如下（采用JSON格式）：
<数据>
{ 数据 }

/ <数据>

请使用 HTML 和 CSS 生成 HTML 表格，并遵循以下要求：

造型要求：

- (1) 您可以使用任何CSS框架、库或工具来构建页面。
- (2) 发挥创意，确保网页在字体、色彩、边框、布局等方面独具特色，同时与主题及目标受众类型相契合。
- (3) 采用适当的设计比例（如页边距、页面尺寸、内容密度等），以确保信息呈现清晰，避免文本重叠或布局问题。
- (4) 所有内容均需显示在单个页面内，切勿使页面过长或布局过于疏松。这是非常重要的要求。

- (6) 所有文本必须位于表格内。

(7) 生成的表格应包含 **rowspan** 或 **colspan** 属性。

代码要求：

- (1) 请将提供的数据直接硬编码到HTML页面中，不要使用任何后端调用。确保HTML语法和格式正确。
- (2) 将 HTML 和 CSS 代码包含在同一个 HTML 文件中，不要使用任何外部资源文件。

输出要求：

请标记代码块。
无需添加任何额外说明文本——输出结果应为一个封装在 (html)/(html) 标签内的单一HTML文件。

可重复性检查清单

作者须知：

本文件概述了评估可重复性所需的关键要素。请直接编辑该.tex文件以提供您的意见。

对于每个适用的问题，请将“在此处输入您的答案”文字替换为您的回答。

示例：如果出现以下问题：

`\question{所有新主张的证明均已包含}{(是/部分/否)}`

在此处输入您的回复，即可将其修

改为：

`\question{所有新提出的主张均包含证明}{(是/部分/否)}`

对

请务必：

- 仅替换“在此处输入您的回复”这段文字，其余内容均无需更改。
- 请使用该问题列出的选项之一（例如：**是**、**否**、**部分**或**NA**）。
- **请勿**修改\question命令的其他部分或本文档中的任何其他行。

您可在主文件的\end{document}之前直接插入此.tex文件，或将其编译为独立文档。请查阅会议官网上的说明，确认是否需要随论文提交该检查清单或需单独提交。

1. 通用论文结构

- 1.1. 包含所介绍的人工智能方法的概念框架和/或伪代码描述（是/部分/否/不适用）是
- 1.2. 明确区分观点、假设和推测性陈述与客观事实及结果（是/否）是
- 1.3. 为不熟悉该文献的读者提供了清晰明确的教学参考信息，帮助其掌握复现论文所需背景知识（是/否）是

2. 理论贡献

- 2.1. 本文是否具有理论贡献？（是/否）否；若为是，请说明以下几点：
 - 2.2. 所有假设和限制均以清晰、正式的方式列出（是/部分/否）请在此处输入您的回答
 - 2.3. 所有新颖性主张均以正式方式表述（例如，在定理陈述中）（是/部分/否）请在此处输入您的回答
 - 2.4. 所有新主张均附有证明材料（是/部分/否）在此处输入您的回复
 - 2.5. 针对复杂和/或新颖的结果提供证明草图或直观说明（是/部分/否）请在此处输入您的回答
 - 2.6. 已对所使用的理论工具进行了适当的引用（是/部分/否）请在此处输入您的回答

- 2.7. 所有理论主张均通过实证研究得到验证（是/部分正确/否/不适用）[请在此处输入您的回答](#)
- 2.8. 所有用于排除或反驳相关主张的实验代码均已包含（是/否/不适用）[请在此处输入您的回答](#)

3. 数据集使用

- 3.1. 本文是否基于一个或多个数据集？（是/否）[是](#)若为是，请说明以下要点：
- 3.2. 文中阐述了为何选择在特定数据集（是/部分/否/不适用）[是](#)上进行实验的动机。
- 3.3. 本文介绍的所有新型数据集均包含在数据附录中（是/部分/否/不适用）[是](#)
- 3.4. 本文介绍的所有新型数据集将在论文发表时公开提供，并附带允许为研究目的免费使用的许可协议（是/部分/否/不适用）[是](#)
- 3.5. 所有从现有文献中提取的数据集（可能包括作者自身先前发表的研究成果）均附有相应的引用信息（是/否/不适用）[是](#)
- 3.6. 所有从现有文献中提取的数据集（可能包括作者先前发表的研究成果）均公开可获取（是/部分/否/不适用）[是](#)
- 3.7. 所有未公开发布的数据集均进行了详细描述，并说明为何公开可用的替代方案在科学上无法满足要求（是/部分/否/不适用）[不适用](#)
- 4. 计算实验。**1. 本文是否包含计算实验？（是/否）[是](#)若为“是”，请说明以下要点：
- 4.2. 本文列出了在论文开发过程中针对每个（超）参数尝试的数值数量及范围，并说明了用于选择最终参数设置的标准（是/部分/否/不适用）[否](#)
- 4.3. 所有预处理数据所需的代码均包含在附录中（是/部分/否）[是](#)
- 4.4. 进行及分析实验所需的所有源代码均包含在代码附录中（是/部分/否）[是](#)
- 4.5. 所有用于开展和分析实验所需的源代码将在论文发表时公开提供，并附带允许为研究目的免费使用的许可协议（是/部分/否）[是](#)
- 4.6. 所有实现新方法的源代码均包含详细说明实现过程的注释，并引用了相关文献。每一步的来源说明（是/部分/否）[是](#)
- 4.7. 若某种算法依赖于随机性，则所使用的种子设置方法需以足以确保结果可重复的方式进行描述（是/部分/否/NA）[NA](#)
- 4.8. 本文明确了用于运行实验的计算基础设施（硬件和软件），包括GPU/CPU型号、内存容量、操作系统以及

相关软件库和框架的名称与版本（是/部分/否）[部分](#)

- 4.9. 本文正式描述了所使用的评估指标，并阐述了选择这些指标（是/部分/否）[是](#)的动机。
- 4.10. 本文列出了计算每项报告结果（是/否）所需的算法运行次数：[是](#)
- 4.11. 实验分析不仅涵盖性能的单维汇总指标（如平均值、中位数），还包含变异度、置信度或其他分布信息（是/否）[是](#)
- 4.12. 任何性能改善或下降的意义均通过适当的统计学检验（例如Wilcoxon符号秩检验）进行评估（是/部分/否）[是](#)
- 4.13. 本文列出了实验中每个模型/算法所使用的全部最终（超）参数（是/部分/否/未指定）[是](#)